

Metagenome Analysis



2026. 농촌진흥청 슈퍼컴퓨터 기반 빅데이터 분석 교육

발표자 : 문재우, 윤경의

발표일 : 2026년 7월 30일

목차

본 강의는 Metagenome 의 이론적 배경부터 연구설계, NGS 데이터 생산, QIIME2 파이프라인 실습 및 유의한 결과 도출을 통한 통계 분석까지 Metagenome 전 과정을 이해를 목적으로 둔다.


- 1. Metagenome 연구 개요**
- 2. Metagenome 과 NGS**
- 3. Metagenome 연구 방법론**
- 4. 미생물 군집 다양성 분석 방법과 사례**
- 5. QIIME2 실습: 결과 해석 및 유의한 결과 도출을 통한 통계분석**

Metagenome 연구 개요

Metagenome 과 Metagenomics 란?




- METAGENOME
: 특정 환경에 존재하는 모든 미생물들의 유전체 집합을 연구하는 학문
- METAGENOMICS
: 특정 환경에 존재하는 모든 미생물들의 유전체 집합을 연구하는 학문

- 미생물(Microbe); 눈에 보이지 않는 생물
 - Bacteria
 - Archaea
 - Fungi
 - Virus, etc.



미생물 검출 방법의 패러다임 변화

- 과거의 미생물 검출은 주로 현미경 관찰이나 배양(Culture)에 의존
- 최근, 미생물 유전자를 직접 해독하는 Sequencing 기술 주로 활용




주요 용어 정리

- **Microbiota (미생물 군집)**
: 특정 환경에 살고 있는 **미생물**들의 모임
- **Microbiome**
: 특정 환경에 존재하는 모든 **미생물**들과 그들의 유전자(genes) 및 유전체 전체
- **Human Microbiome**
: 인체 내에 서식하는 **세균**(Bacteria), **진균**(Fungi), **바이러스**(Virus) 등의 총집합

주요 용어 정리: Dysbiosis

질병의 상태와 연관되어 나타나는 미생물 군집의 불균형 상태



장내 불균형 발생 = 유익균 ↓, 유해균 ↑

: 장내 염증 유발, 장 점막층 약화

- 유해균 생물막(Biofilm) 구성 단백질(ex. Flagella, LPS, Propylene 등)이 장내 면역세포 자극
- 염증성 cytokine 분비(ex. IL-18, IL-12, TNF- α 등)
- 유해균 독소 □ DNA 절단, 장내 상피세포 손상

세계적인 마이크로바이옴 프로젝트: HMP

HMP (Human Microbiome Project)

: 인체 다양한 부위 (장, 구강, 피부 등)의 건강한 미생물 군집을 규명하고 질병과의 연관성을 찾는 대형 프로젝트




미국 국립보건원 (NIH) 에서 주관한 인체 마이크로바이옴 프로젝트
> HMP1 (2008~2012)

인체 마이크로바이옴 Reference Genome 데이터베이스 구축
연구 기술 및 분석 방법을 개발하여 연구자들 제공

> HMP2 (iHMP, 2013 ~2016)

3가지 질병 (염증성 장질환, 제2형 당뇨, 임신과 조산) 중점으로
마이크로바이옴 기능 규명




세계적인 마이크로바이옴 프로젝트: MetaHIT

유럽을 중심으로 인간 장내 미생물의 유전자 카탈로그를 구축하고 Enterotypes를 발견




- 유럽연합 국제 컨소시엄에서 주관한 인체 장내 메타게놈 프로젝트
- 장내 마이크로바이옴을 중심으로 인간의 건강과 연관성 확인
- 건강한 사람과 질환을 보유한(염증성 장질환 IBD, 비만)의 장내 미생물 내 유전자 구성 차이 확인
- 박테리아 유전자의 기능과 질병의 상관관계 분석



마이크로바이옴 연구의 중요성: FMT

FMT (Fecal Microbiota Transplantation)

: 건강한 사람의 대변 미생물을 환자에게 이식하는 치료법




<https://youtu.be/-nDPjGAGEak?si=9V33dNH29H9bsOKf>

- *Clostridium difficile* infection (CDI) 환자에게 FMT 치료
- CDI; 항생제 복용에 따른 내성 CD균 로 설사일으키는 질병
- 치료 후, 항생제 내성 박테리아 감소 및 공여자 장내 미생물 조성으로 재확립.
- 환자의 90% 가 며칠안에 완치되는 효과를 보임. (2016 국내 치료기술 등록)

Metagenome 과 NGS

Sequencing 과 NGS의 개념


- Sequencing (시퀀싱): 염기의 순서를 화학적으로 읽어내는 것 (=염기 서열 해독)
- NGS (Next-Generation Sequencing)
: 수많은 DNA를 병렬로 동시 해독하여 단기간에 방대한 데이터를 생산하는 차세대 염기서열 분석 기술, 배양 없이 여러 종의 유전자를 분석할 수 있음.



ATTGCAGT...
TAACGTCA

Sequencing 기기의 발전 역사

- 1977년 수동 Sanger 시퀀싱 ~ 2005년 454 장비를 거쳐 비약적으로 발전
- 이후 Illumina의 MiSeq/HiSeq, PacBio, MinION 등이 도입



↓ Cost

↑ Analysis (BI)

Metagenome 분석의 핵심 질문


Diversity(종다양성)

Abundance(개체 수)

“어떤 미생물이 얼마나 존재하는가?”
“자연/숙주 환경과 어떤 상호작용을 하는가?”

Function(기능)


접근법1: Amplicon Sequencing



BOWMAN, Brittany A., et al. Efficient nucleic acid extraction and 16S rRNA gene sequencing for bacterial community characterization. *JoVE (Journal of Visualized Experiments)*, 2016, 110: e53939.


- 환경 내 미생물들의 특정 유전자 영역(16S rDNA, ITS 등)만을 PCR로 증폭하여 시퀀싱
- 비용이 저렴하고 미생물 종 다양성(Abundance)을 파악하는 데 효과적이나, 기능(Function) 예측이 어렵고 해상도가 낮음

Target DNA: 16S rRNA 유전자의 특징



- 세균의 계통 발생을 연구하는 데 쓰이는 약 1,500bp 길이의 마커 유전자임
- 모든 세균이 가지는 보존적인 염기서열(Conserved regions)과 종마다 달라지는 다양성 염기서열(Variable regions, V1~V9)이 교차로 존재함


16S rDNA Primer 및 타겟 영역 설정




- 보존적 영역에 Universal primer를 결합하여 가변 영역을 증폭함.
- Illumina MiSeq PE 환경에서는 주로 ~428bp 길이의 V3-V4 영역을 타겟으로 함.
- PacBio와 같은 Long read 장비는 V1-V9 전체(Full-length)를 분석할 수 있음.

Amplicon Sequencing Analysis


Amplicon Metagenome




Bacterial genomes
present in a sample



PCR-amplified
rRNA genes
(16S rRNA genes)




접근법2: Shotgun Metagenomic Sequencing



- 샘플 내 모든 유전자 영역을 잘게 잘라 시퀀싱
- 미생물의 기능(Function)과 고해상도 분석이 가능하지만, 비용이 비싸고 숙주 (Host) 유전자가 섞일 우려가 있음

Shotgun sequencing Analysis


Shotgun Metagenome



Bacterial genomes
present in a sample




Genomes cut into
small fragments



⇒ Host gene 제거

Metagenome Sequencing

“Amplicon 과 Shotgun 의 차이를 이해하고 연구 목적에 적합한 방법을 이용한다!”



연구 목적에 따른 시퀀싱 장비 선택

- MiSeq i100: 5M ~ 100M reads를 생산하며 Amplicon 분석에 널리 쓰임.
- NovaSeq X: High throughput 장비로 Shotgun 분석에 적합함.
- Sequel/Revio: PCR 증폭 없이 긴 리드를 생성함.(10kb ~ 25kb)



MiSeq i100




Novaseq X




Sequel

Amplicon Sequencing의 Low Quality 극복

Amplicon은 염기 다양성이 낮아 기기 에러가 발생하기 쉬움.




1. Cluster density를 낮게!




Amplicon Sequencing의 Low Quality 극복

Amplicon은 염기 다양성이 낮아 기기 에러가 발생하기 쉬움.




2. PhiX를 섞어 염기서열 다양성을 높게!



Amplicon Sequencing의 Low Quality 극복

Amplicon은 염기 다양성이 낮아 기기 에러가 발생하기 쉬움.




3. Forward/Reverse 리드의 Overlap 영역확보

Overlap 영역의
quality가 높을수록!
정확도 높음!

Metagenome 연구 방법론

Metagenome 연구 5단계 프로세스

연구는 일반적으로 다음의 단계를 거칩니다:



1단계: 연구 계획 수립

2단계: 샘플 채취

3단계: 데이터 생산

4단계: 데이터 분석

5단계: 결과 해석

1단계: 연구계획 수립

< 효과의 검증 >



비치료 VS. 치료 (독립표본 설계)

- 각 그룹 내 샘플 수가 달라도 됨.
- 비교적 짧은 기간 내 샘플 수집 가능
- 치료제 투여하지 않은 그룹에 대한 기준이 모호함
- 개인 간 효과 차이 보기 어려움



치료 전 VS. 치료 후 (대응 표본 설계)

- 각 그룹 내 샘플 수 동일하게 유지
- 동일 개체의 변화량을 고려한 치료 효과 검증
- 샘플 수집이 어려움이 따를 수 있음.

1단계: 가설 검정과 다중 검정 문제 (FDR)

< 효과의 검증 방법 >

- 가설 검정

- 귀무가설: 두 그룹 간 차이가 없음.

예) *Lactobacillus* p-value = 0.01

⇒ 귀무가설 기각, 대립가설 채택 (두 그룹 간의 차이가 있음)

- p-value < 0.05 기준을 수백 종의 미생물에 반복 적용하면 1종 오류(위양성) 발생

- 보정방법: FDR (False Discovery Rate)

: 귀무가설을 기각한 검정 중 틀린 것의 비율을 조절

2단계: 샘플 채취 시 고려사항


Q. 샘플 채취 **키트**는 어떤 것을 사용해야 하는가?

- 샘플 채취 키트(Kit) 종류에 따라 검출되는 미생물의 종류나 PCR Cycle 효율에 차이가 날 수 있으므로 프로젝트 내 일관된 키트 사용이 권장됨.

3단계: 샘플의 보관 및 이동 가이드라인


Q. 샘플 보관 기간은 얼마나 되는가?

- 동결보관: 채취 즉시 -80°C 초저온 냉동 보관 (장기 보관을 위해서는 필수적임)
- 상온보관: 보존 시약(DNA stabilizer)사용, 상온에서 수일~수주 보관 가능
- Fresh sample: 실온에서 4시간 이내, 또는 4°C 냉장 상태에서 24~48시간 이내에 실험실로 이동.



4단계: 데이터 생산 (Depth 고려)

- 연구 목적과 다양한 기기의 특성을 고려하여 데이터 생산




Whole genome
Specific region

Reference O
Reference X



4단계: 데이터 생산 (Depth 고려)

- 분석에 필요한 **충분한 데이터를 확보**해야 함.




희소성 분석(Rarefaction curve)

: 시퀀싱 뎀스(Sequence depth)가 증가해도 발견되는 OTU/ASV 수가 더 이상 늘어나지 않는 평탄한 구간에 도달할 수 있도록 데이터 생산량을 설계해야 함.


OTUs vs ASVs의 개념적 차이

OTU 방식
(Operational Taxonomic Units)




**97% 서열의 유사도 그룹화
(Clustering)**

ASV 방식
(Amplicon Sequence Variants)




**오류 모델(DADA2, Deblur)
기반 시퀀싱 기기오류 제거
(Denoising)**

OTUs vs ASVs의 개념적 차이




- 다른 미생물이 **Clustering** 됨
- 실험마다 **OTU** 결과가 달라
타 연구와 비교가 어려움



- 해상도가 높음
- 데이터베이스 없이도 연구간
비교/재현성 뛰어남

5단계: 데이터 분석



<Amplicon sequencing>

- ⇒ Remove Primer/Adapter
- ⇒ Quality Control & Filtering
- ⇒ Denoising / Clustering
- ⇒ Taxonomy assignment
- ⇒ Diversity

<Shotgun Sequencing>


- ⇒ Remove Adapter & QC
- ⇒ Host Genome Removal
- ⇒ Taxonomy & Functional Profiling
- ⇒ (option) Assembly & Binding
- ⇒ Diversity & Downstream Analysis

5단계: 데이터 분석

Overview of generic* metagenomics workflow

*This is generic; specific workflows can vary on the order of steps here and how they are done.

When working with your own data you should never follow any pipeline blindly. There can be critical differences based on your data.



전처리(Preprocessing)의 중요성

- 시퀀싱 에러 요소를 제거해야 함.
 - Read length filter: 타겟 영역에 맞는 리드만 남김.
(예: 16S V3V4 400~500bp)
 - Low quality: Phred score Q20 미만 등의 저품질 염기를 제거
 - Ambiguous base: N base를 포함한 리드를 제거함.
 - Chimeric read: PCR 과정에서 섞여 생성된 가짜 서열을 제거함.

미생물 군집 분석 방법

군집 다양성(Community Diversity)의 두 축

미생물 군집 다양성 분석

: 시퀀싱을 통해 얻은 메타 유전체 데이터의 다양성을 평가하기 위해 크게 두가지 관점 (Alpha 및 Beta Diversity)로 접근

- Alpha Diversity


- 하나의 샘플 내(Within samples)에 존재하는 종의 다양성 분석
- 특정 자연/숙주 환경 (예: 한 환자의 장내)에 미생물이 얼마나 풍부하고 고르게 분포하는지 확인

- Beta Diversity

- 샘플과 샘플 사이(Between samples)의 군집 구성 차이와 유사도를 분석
- 치료군과 대조군 등 그룹 간 미생물 군집이 어떻게 달라지는지 유연관계를 파악하는 데 핵심적으로 사용


Alpha Diversity: 단일 샘플내 미생물 풍부도/균등도

- Richness (풍부도): 관측된 미생물 종 (Species) 의 수
 - 대표 지표: Observed features, Chao1 index
- Evenness (균등도): 특정 종에 치우치지 않고 얼마나 고르게 분포하는지 측정 값
 - 대표 지표: Pielou's Evenness, Simpson index



Beta Diversity: 샘플 간 군집 구조 비교 및 시각화

- 거리 기반 군집 유사도 측정 메트릭스



정량적 메트릭스

(Bray-Curtis, weighted UniFrac)

: 미생물 비율에서 차이로 우점종 확인

정성적 메트릭스




(Jaccard, unweighted UniFrac)

: 미생물 유무에서 차이로 희귀종 변화 확인

Beta Diversity: 샘플 간 군집 구조 비교 및 시각화



- 다변량 통계 시각화 (PCoA 주좌표 분석)
 - 샘플간의 거리 (Dissimilarity) 행렬 기반으로 다변량 데이터의 차원을 축소하여 2D, 3D좌표로 시각화
 - 샘플을 나타내는 점들이 가깝게 군집(Clustering) 할수록 미생물 군집 조성이 매우 유사함.

a



Taxonomy (분류군) 및 Phylogeny (계통) 분석

- Taxonomy (분류군) 식별 및 분석
 - 전처리 된 OTU/ASV 서열을 Reference Database (GreenGene2, SILVA, NCBI 16S) 로 식별
 - Phylum (문) ~ Species(종) 단계의 미생물 상대적 분포 비율(Relative abundance) 산출



Phylogenetic tree showing the relationships between various *Lactobacillus* strains based on 16S rDNA sequences. The tree is rooted on the left, and the scale bar indicates a distance of 0.02 substitutions per site.

Strains and their corresponding bootstrap values (from top to bottom):

- Lactobacillus zeae* D86516.1 (100)
- Lactobacillus casei* AB008204.1 (100)
- Lactobacillus composti* AB268118.1 (43)
- Lactobacillus parafarraginis* AB262734.1 (74)
- Lactobacillus farraginis* AB262732.1 (41)
- Lactobacillus buchneri* M58811.1 (83)
- Lactobacillus parakefiri* AY026750.1 (100)
- Lactobacillus kefir* AJ621553.1 (99)
- Lactobacillus parabuchneri* AY026751.1 (70)
- C11 JN188391** (100)
- C12 JN188392** (100)
- C13 JN188393** (98)
- Lactobacillus salivarius* DQ444477.1 (98)
- Lactobacillus aviaris* M58808.1 (98)
- Lactobacillus saerimneri* AY255802.1 (98)
- Lactobacillus vini* AJ576009.1 (82)
- Lactobacillus mali* M58824.1 (54)
- Lactobacillus satsumensis* AB154519.1 (100)
- Lactobacillus bifementans* M58809.1 (100)
- Lactobacillus coryniformis* M58813.1 (100)
- Lactobacillus fuchuensis* AB063479.1 (100)
- Lactobacillus graminis* AM113778.1 (100)
- Lactobacillus curvatus* AM113777.1 (100)
- Lactobacillus sakei* AY204893.1 (60)
- Lactococcus lactis* AB100803.1

-